WeDataLab

벡터 데이터베이스 실습

2025년 02월

© Copyrights 2025. Wedatalab All Rights Reserved.

대표적인 벡터 데이터베이스

특징	ChromaDB	Pinecone	Weaviate
오픈소스	✅	❌	✅
Python 친화성	✅	✅	✅
분산 지원	✅	✅	✅
실시간 업데이트	✅	❌	✅
커뮤니티 지원	활발	제한적	활발

목차

- ChromaDB 실습
- Weaviate 실습
- 요 약

ChromaDB 실습

ChromaDB

- 2022년: Chroma 프로젝트 시작. 생성형 AI와 LLM의 성장에 따라 벡터 데이터베이스의 필요성에 대응해 개발 착수.
- 2023년: ChromaDB 오픈소스 출시**. LangChain 및 OpenAI API와 통합**되며 생성형 AI 애플리케이션에서 주목받음.
- 2023년: 대규모 데이터셋 처리 및 실시간 검색 기능 강화, 커뮤니티 성장과 GitHub에서 활발한 활동 진행.
- 2024년 이후 (예상): 실시간 데이터 처리, 멀티모달 데이터 지원 등 기능 확장과 클라우드 기반 확장성 강화 전망.

특징	설명
빠른 성능	임베딩 저장 및 검색이 매우 빠르고 효율적
파이썬 네이티브	파이썬으로 개발되어 파이썬 생태계와의 통합이 용이
다양한 백엔드	SQLite, PostgreSQL 등 여러 백엔드 시스템 지원
멀티테넌시	기업 환경에 적합한 멀티테넌트 아키텍처 지원
메타데이터 필터링	강력한 메타데이터 필터링 기능 제공
REST API	API를 통한 접근 가능
로컬 실행	로컬 환경에서 실행 가능하여 개발/테스트 용이
오픈소스	무료로 사용 가능한 오픈소스 라이선스

ChromaDB 구성

•Tenant (테넌트)
- ✓ 가장 상위 수준의 격리 단위
- ✓ 다수의 데이터베이스
- ✓ 조직이나 사용자 그룹 분리

•Database (데이터베이스)
- ✓ 테넌트 내에 논리적 컨테이너
- ✓ 독립적인 collection 포함

•Collection (컬렉션)
- ✓ 임베딩과 메타데이터를 저장하는 기본 단위
- ✓ 유사한 특성을 가진 문서나 데이터를 그룹화
- ✓ 고유한 스키마와 설정
- ✓ 벡터 검색, 필터링, CRUD 작업 수행

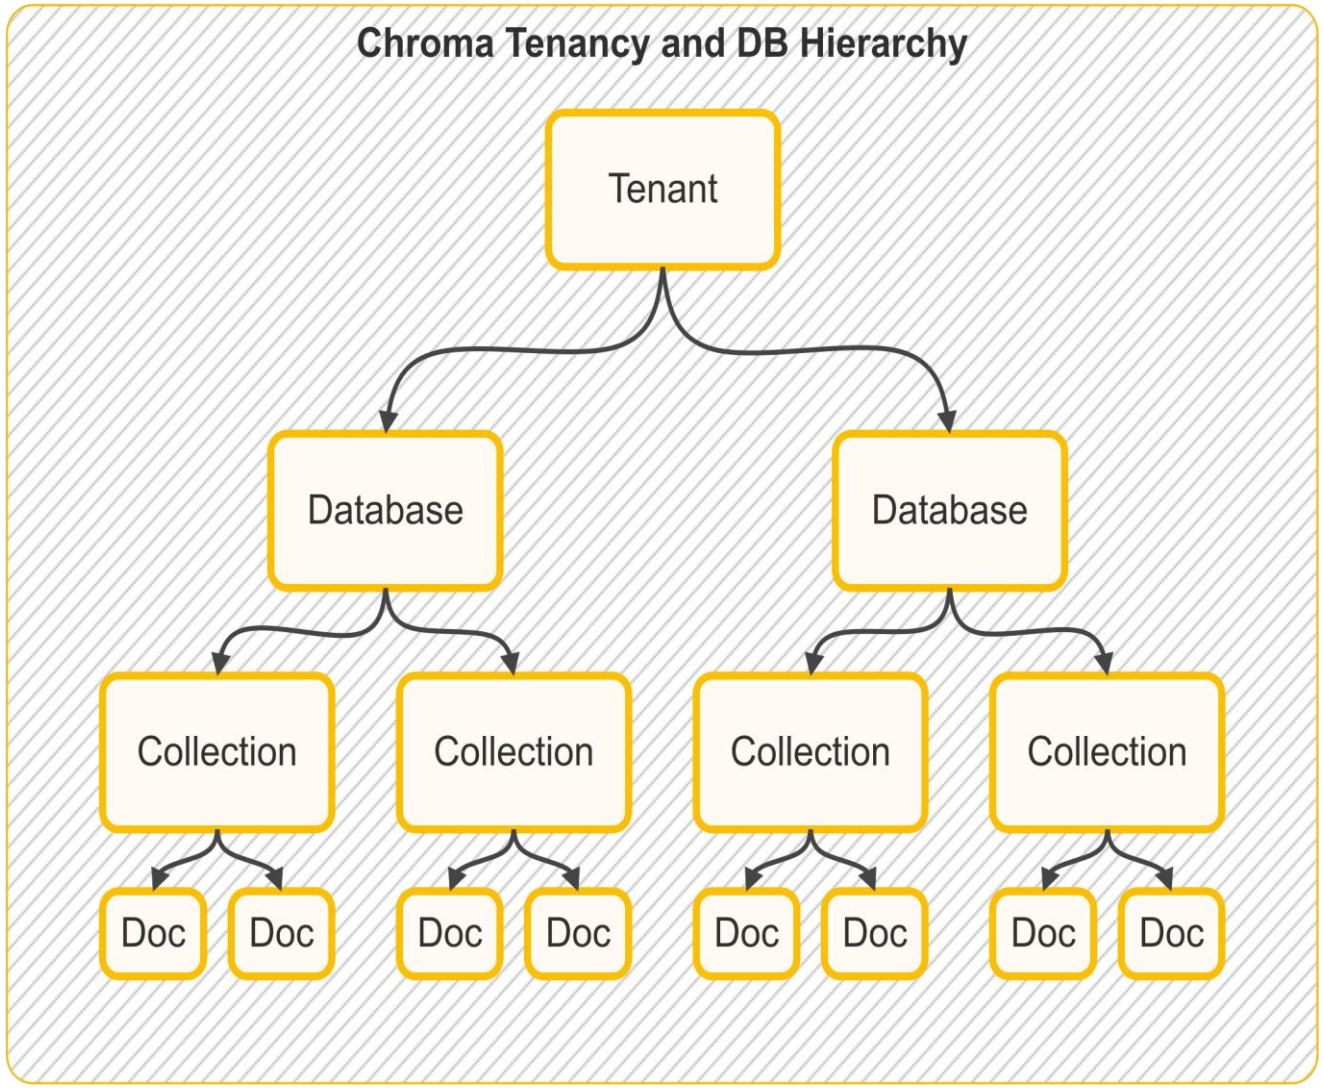

출처 : https://cookbook.chromadb.dev/core/concepts/#tenancy-and-db-hierarchies

ChromaDB 실습

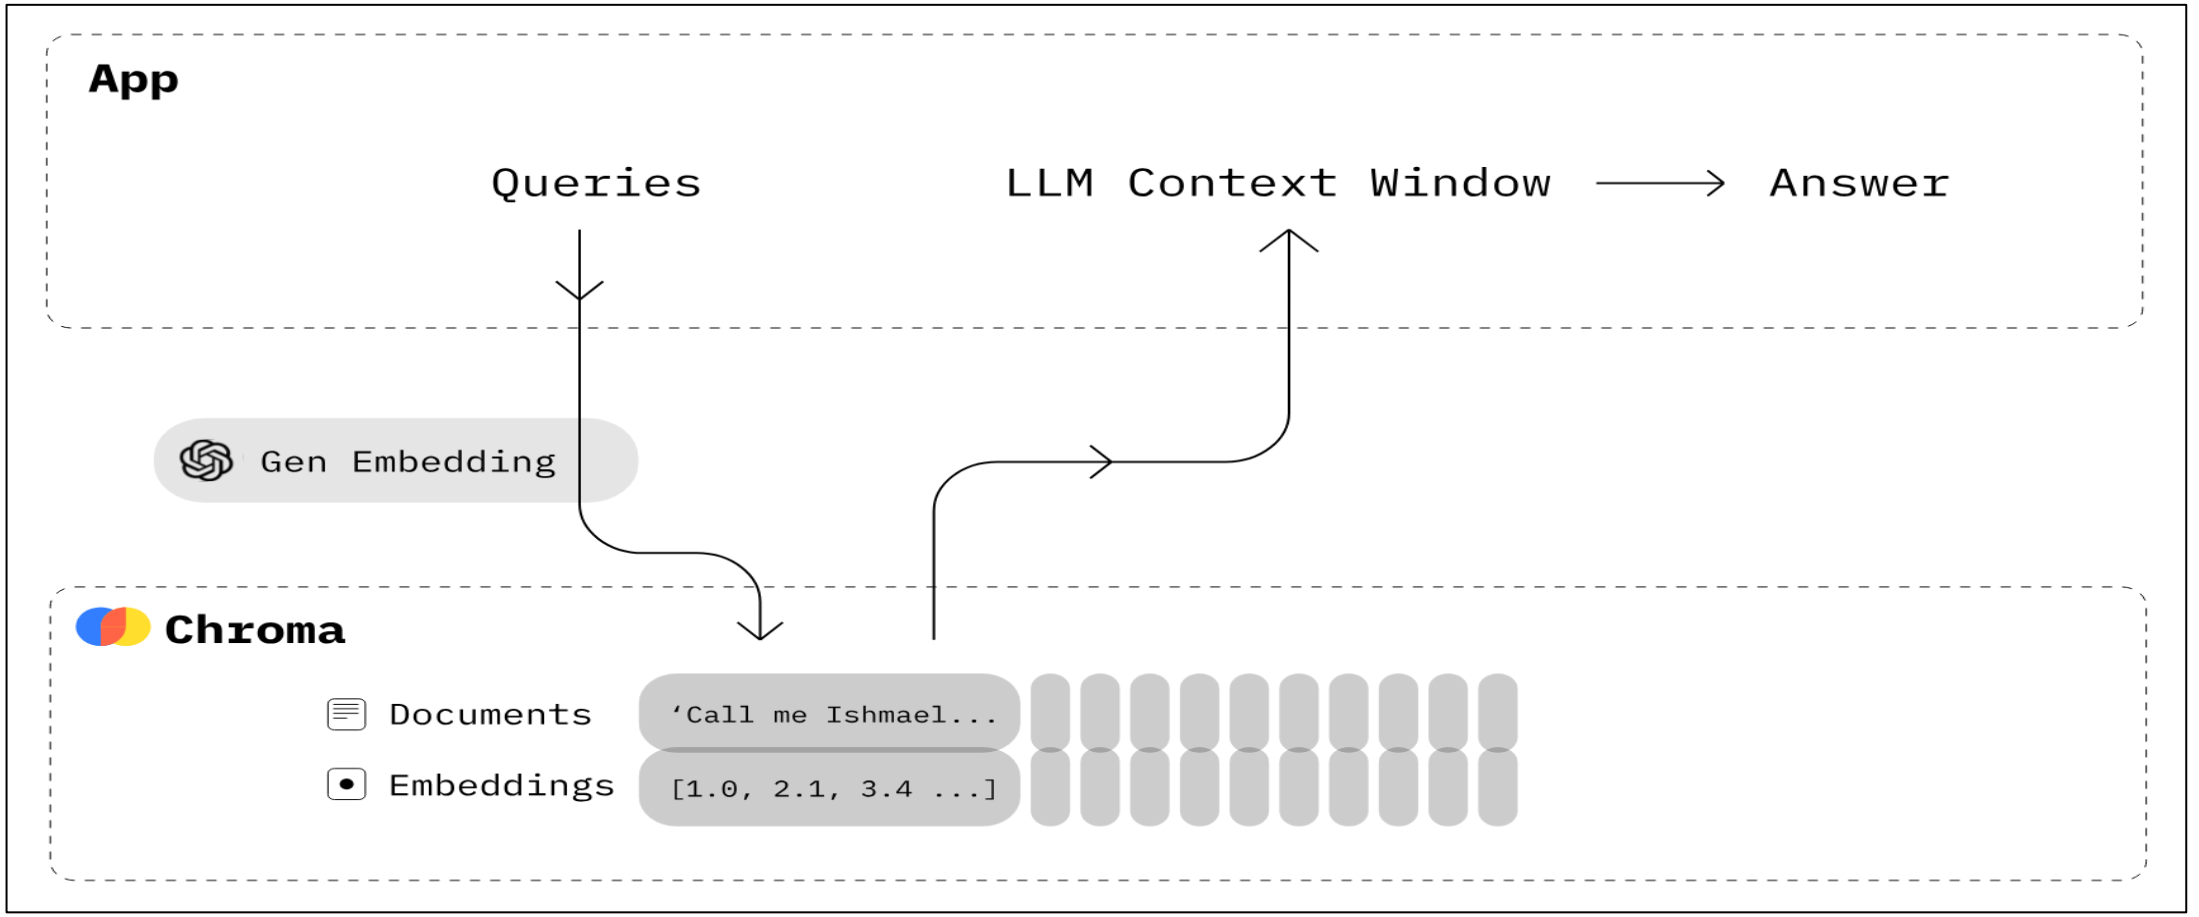

출처 : https://opentutorials.org/module/6369

ChromaDB + Embedding 실습
실습 : https://colab.research.google.com/drive/1QIv8Te_U_-X0C7YFvfxiW2doddVSoP7p?usp=sharing

ChromaDB 실습

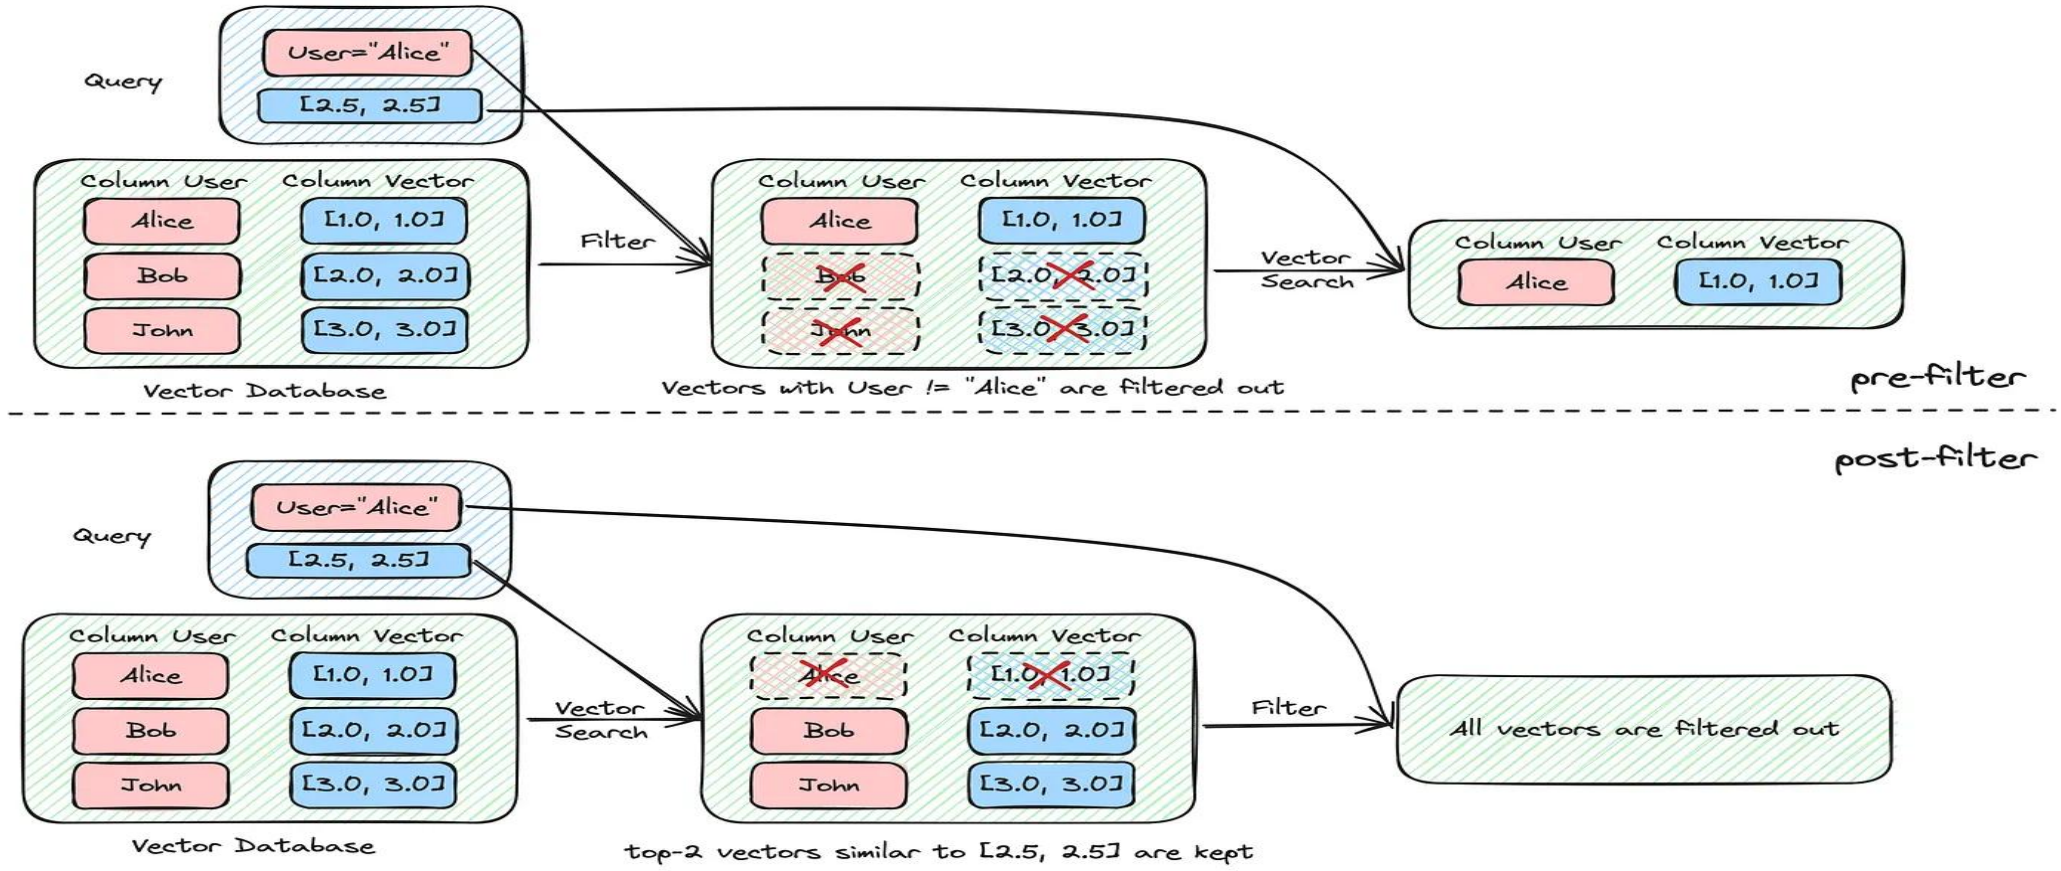

출처 : https://medium.com/@myscale/optimizing-filtered-vector-search-in-myscale-77675aaa849c

ChromaDB + 필터 실습
실습 : https://colab.research.google.com/drive/1isvHKC4s6dZHxEhZVZEEX8J1natTYlvF?usp=sharing

Weaviate 실습

Weaviate

- 2018년: 네덜란드의 'Semi Technologies 에서 비정형 데이터 관리를 위한 Weaviate 프로젝트 시작
- 2019년: 첫 오픈소스 벡터 검색 데이터베이스 출시. NLP와 벡터 저장 중심.
- 2022년: Weaviate의 성능과 확장성 강화. 대규모 데이터셋 처리 및 새로운 인덱스 기술 도입.
- 2023년: 커뮤니티 성장 . RAG(검색 증강 생성) 기술과 통합된 애플리케이션 개발 활성화.
- 2024년: 다중 테넌시 기능 개선, 실시간 업데이트 및 멀티모달 데이터 지원 확대

특징	설명
확장성	수평적 확장이 가능한 분산 아키텍처 지원
GraphQL API	직관적인 GraphQL 인터페이스 제공
실시간 벡터화	데이터 입력 시 자동 벡터화 지원
다중 샤딩	대규모 데이터셋 처리를 위한 샤딩 지원
CRUD 작업	벡터와 객체에 대한 완전한 CRUD 작업 지원
멀티 테넌시	기업용 멀티 테넌트 지원
보안 기능	인증, 권한 관리 등 엔터프라이즈급 보안 제공
다양한 인덱싱 지원	여러 벡터 인덱스 백엔드 지원 (HNSW, LSH 등)

Weaviate 구성

- **클래스(Class):** 데이터의 카테고리 또는 타입

예: "Book", "Movie", "Product" 등.

- **속성(Properties):** 클래스 안에 저장되는 데이터의 세부 항목

예: 제목, 저자, 출판연도 등.

- **데이터 타입(DataType):** 각 속성에 저장되는데이터의 유형

예: 문자열(string), 숫자(int), 벡터(vector) 등

json

```
{
  "class": "Book",
  "properties": {
    "title": "1984",
    "author": "George Orwell",
    "publicationYear": 1949,
    "embedding": [0.12, 0.85, 0.33, 0.44]
  }
}
```

json 복사 편집

```
{
  "classes": [
    {
      "class": "Book",
      "description": "A collection of written works",
      "properties": [
        {
          "name": "title",
          "dataType": ["string"],
          "description": "The title of the book"
        },
        {
          "name": "author",
          "dataType": ["string"],
          "description": "The author of the book"
        },
        {
          "name": "publicationYear",
          "dataType": ["int"],
          "description": "The year the book was published"
        },
        {
          "name": "embedding",
          "dataType": ["vector"],
          "description": "Vector representation of the book's content"
        }
      ]
    }
  ]
}
```

Weaviate 실습

1. `with_near_text`

- **설명:** 텍스트 기반으로 데이터의 유사성을 평가.
- **사용 예:** 특정 개념과 의미적으로 유사한 데이터를 검색.
- **옵션 필드:**
  - `concepts`: 텍스트 벡터화의 기준이 되는 단어나 문장.
  - `distance`: (선택 사항) 결과와의 최대 거리.
  - `certainty`: (선택 사항) 검색 결과의 최소 유사도 (0~1 사이의 값).

예시:

python 복사 편집

```python
.with_near_text({
    "concepts": ["biology", "organisms"],
    "certainty": 0.8
})
```

2. `with_near_vector`

- **설명:** 벡터 데이터를 직접 사용해 유사성을 평가.
- **사용 예:** 특정 벡터와 가장 가까운 데이터를 검색.
- **옵션 필드:**
  - `vector`: 유사성 비교에 사용할 벡터 값.
  - `distance`: (선택 사항) 최대 허용 거리.
  - `certainty`: (선택 사항) 최소 유사도.

예시:

python

```python
.with_near_vector({
    "vector": [0.12, 0.56, 0.78],
    "distance": 0.1
})
```

3. `with_near_object`

- **설명:** 기존 Weaviate 객체의 ID를 기준으로 유사한 데이터를 검색.
- **사용 예:** 특정 객체와 유사한 데이터를 찾고 싶을 때.
- **옵션 필드:**
  - `id`: 기준이 되는 객체의 UUID.
  - `distance`: (선택 사항) 최대 허용 거리.
  - `certainty`: (선택 사항) 최소 유사도.

예시:

python

```python
.with_near_object({
    "id": "123e4567-e89b-12d3-a456-426614174000"
})
```

4. `with_near_image`

- **설명:** 이미지 데이터를 기준으로 유사한 이미지를 검색.
- **사용 예:** 업로드된 이미지와 유사한 이미지를 찾고 싶을 때.
- **옵션 필드:**
  - `image`: Base64로 인코딩된 이미지 데이터.
  - `distance`: (선택 사항) 최대 허용 거리.
  - `certainty`: (선택 사항) 최소 유사도.

예시:

python

```python
.with_near_image({
    "image": "..."
})
```

Weaviate CRUD
실습 링크 : https://colab.research.google.com/drive/1LEi1jMTwhNv2VDa4IBS7UTiVWrQAItwq?usp=sharing

Weaviate 실습

```
response = (
    client.query
    .get("JeopardyQuestion", ["question", "answer"])
    .with_hybrid(query="food", alpha=0.5)
    .with_limit(5)
    .do()
)
```

```
response = (
    client.query
    .get("JeopardyQuestion", ["question", "answer"])
    .with_near_text({"concepts": ["food"]})
    .with_limit(5)
    .do()
)
```

```
response = (
    client.query
    .get("JeopardyQuestion", ["question", "answer"])
    .with_bm25(query="food")
    .with_limit(5)
    .do()
)
```

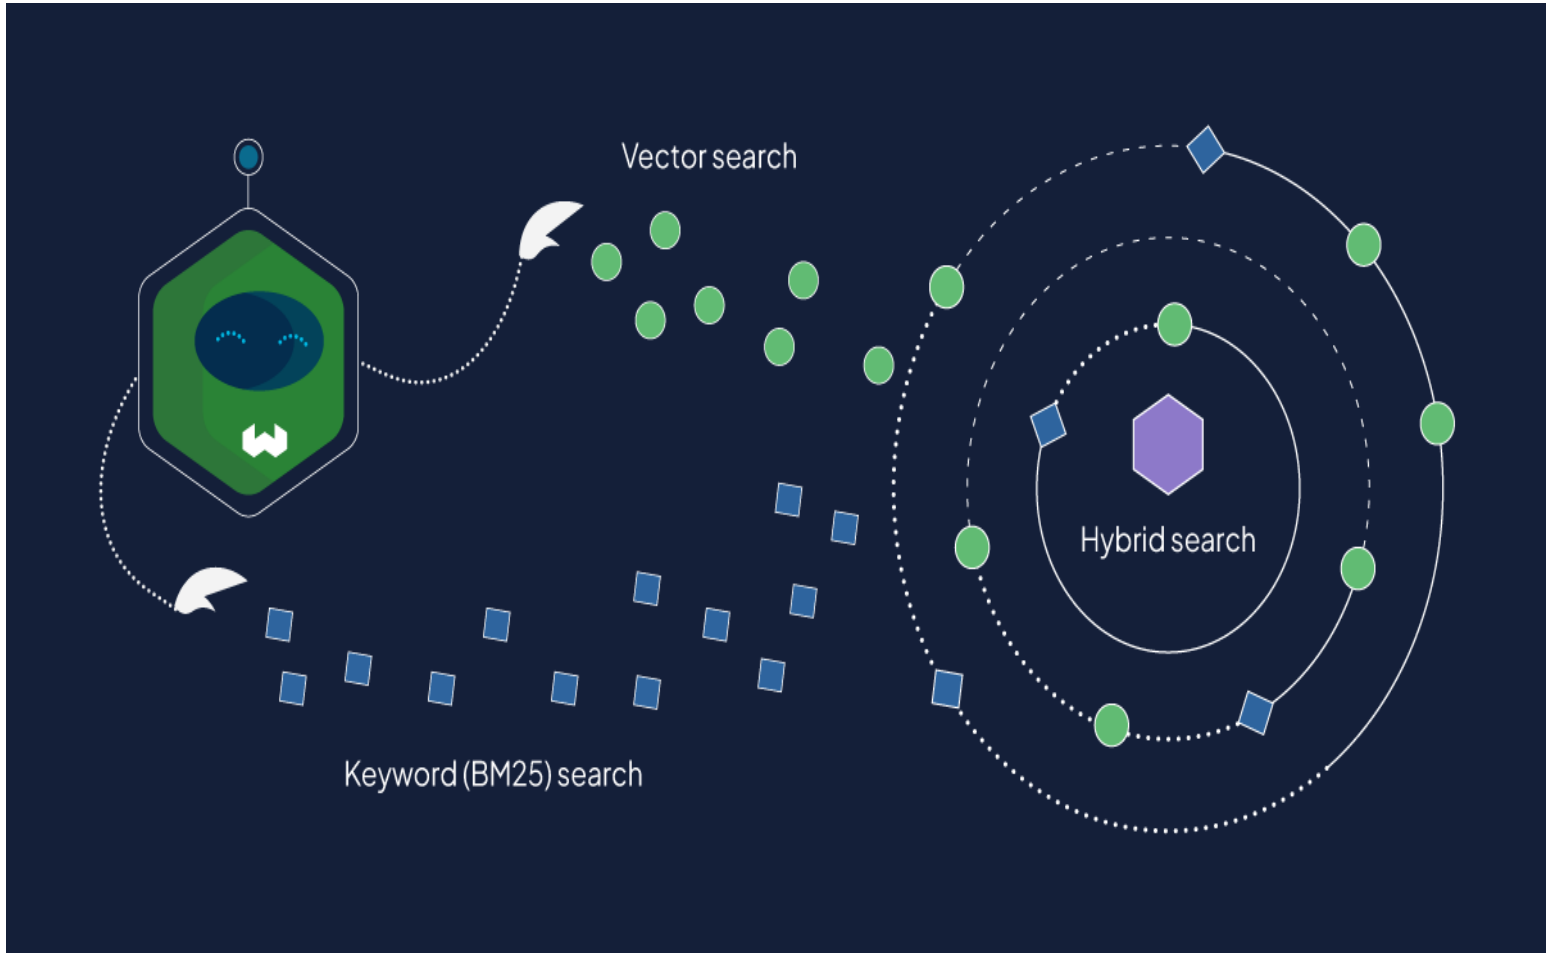

출처 : https://weaviate.io/blog/hybrid-search-fusion-algorithms

Weaviate 하이브리드 검색
실습 : https://colab.research.google.com/drive/1VJnj1egMGILGrW7TSFBYAldD_bcDwyQL?usp=sharing

요 약

요약

1. Chroma:

- **"Chroma"**는 그리스어에서 유래하며, **"색"**을 의미합니다.
- **색상**과 관련된 단어로, **다양한 색의 조합과 다양성**을 나타냅니다. 여기서 **Chroma**는 **다양한 데이터의 특성과 차이를 표현하는** 방식이나 **다채로운 정보**를 의미하는 데 사용됩니다.

2. DB:

- **"DB"**는 **Database**의 약어로, **데이터베이스**를 의미합니다.

ChromaDB의 의미:

- **"ChromaDB"**는 **다양한 특성을 지닌 데이터를 다루는 데이터베이스**라는 의미를 내포하고 있습니다. 특히 **다양한 형태의 데이터(텍스트, 이미지, 음성 등)를 처리하고, 그 속성들을 벡터화하여 관리**하는 데 초점을 둡니다.
- 또한, **Chroma**는 **색**을 뜻하기 때문에, **데이터의 "다채로운" 특성을 잘 포착하여 관리하는 시스템**이라는 점에서도 이 이름이 적합합니다.

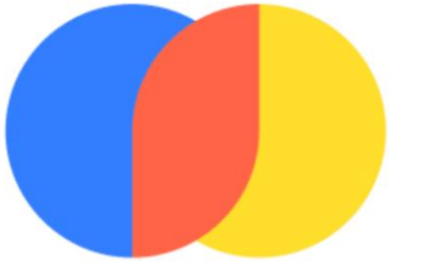

Chroma

Weaviate의 이름은 **"we"**와 **"navigate"**의 결합으로 만들어졌습니다. 이 이름은 **"우리가 함께 데이터를 탐색하고, 연결한다"**는 의미를 담고 있습니다.

어원 및 의미:

- **"We"**: 사람들이 함께 협력하여 지식을 만들고 탐색하는 의미.
- **"Navigate"**: 데이터를 탐색하고, 그 안에서 필요한 정보를 찾아가는 과정을 의미.

따라서 **Weaviate**는 **"우리가 함께 데이터를 탐색하고, 이해하고, 연결해 나간다"**는 비전을 가진 벡터 데이터베이스라는 의미를 지니고 있습니다. 이는 **정보의 연결**과 **지식의 탐색**을 핵심으로 하는 **Semantic Web**이나 **AI 기반 데이터 처리**의 철학을 반영하는 이름입니다.

Weaviate

WeDataLab

감사합니다.

© Copyrights 2025. Wedatalab All Rights Reserved.